0.1 Partielle Ableitungen

$m = f'(x_0)$ im Punkt $(x_0, f(x_0))$

Tangentengleichung

Beispiel: P(1,3)

$$t_x = \underbrace{f(x_1,x_2)}_{\text{f(1,3)}} + \underbrace{\frac{\delta f}{\delta x_1}(x_1^{(0)}, x_2^{(0)})}_{\text{nach } x_1} * (x_1 - x_1^{(0)}) + \underbrace{\frac{\delta f}{\delta x_2}(x_1^{(0)}, x_2^{(0)})}_{\text{nach } x_2} * (x_2 - x_2^{(0)})$$

0.2 Linearisierung von Funktionen

Jacobi-Matrix Df(x)

Jacobi-Matrix enthält sämtliche partiellen Abl.1.Ord.von f:

$$\begin{bmatrix} \frac{\delta f_1}{\delta x_1} & \frac{\delta f_1}{\delta x_2} & ... & \frac{\delta f_1}{\delta x_n} \\ \frac{\delta f_2}{\delta x_1} & \frac{\delta f_2}{\delta x_2} & ... & \frac{\delta f_2}{\delta x_n} \\ \frac{\delta f_m}{\delta x_1} & \frac{\delta f_m}{\delta x_2} & ... & \frac{\delta f_m}{\delta x_n} \end{bmatrix}$$

Beispiel:

$$f(x) = \begin{bmatrix} f_1(x_1,x_2) \\ f_2(x_1,x_1) \end{bmatrix} = \begin{bmatrix} x_1^2 + x_2 - 11 \\ x_1 + x_2^2 - 7 \end{bmatrix}$$

$x^{(0)} = (1,1)^T$

Partielle Ableitung:

$$Df(x_1,x_2) = \begin{bmatrix} 2x_1 & 1 \\ 1 & 2x_2 \end{bmatrix}$$

An der Stelle $x^{(0)}$:

$$Df(x_1^{(0)}, x_2^{(0)}) = \begin{bmatrix} 2 & 1 \\ 1 & 2 \end{bmatrix}$$

Linearisierung:

$g(x) = f(x^{(0)}) + Df(x^{(0)}) * (x - x^{(0)})$

$$g(x_1,x_2) = \begin{bmatrix} -9 \\ -5 \end{bmatrix} + \begin{bmatrix} 2 & 1 \\ 1 & 2 \end{bmatrix} * \begin{bmatrix} x_1 - 1 \\ x_2 - 1 \end{bmatrix} = \begin{bmatrix} 2x_1 + x_2 - 12 \\ x_1 + 2x_2 - 8 \end{bmatrix}$$

Gleichung der Tangentialebene:

Alle angelegten Tangenten an die Bildfläche $y = f(x-1, x_2)$ im Flächenpunkt $P = f(x_1^{(0)}, x_2^{(0)})$

0.3 Das Newton-Verfahren für Systeme

- Konvergiert quadratisch wenn Df(x) regulär, und f 3-mal stetig differenzierbar ist.
- Vereinfachtes Newton Verfahren konvergiert linear.

Mögliche Abbruchkriterien: $\in > 0$

1. $n \geq n_{max}$ (bestimmte Anzahl Iterationen)
2. $\|x^{n+1} - x^n\| \leq \|x^{n+1}\| * \in$ (relativer Fehler)
3. $\|x^{n+1} - x^n\| \leq \in$ (absoluter Fehler)
4. $\|f(x^{n+1})\| \leq \in$ (max residual)

Algorithmus:

1. $Df(x^n)\delta^n = -f(x^{(n)})$
2. nach δ^n auflösen
3. $x^{n+1} = x^n + \delta^n$

0.3.1 Vereinfachtes Newton-Verfahren

Konvergiert nur noch linear!!
Natürlich deutlich langsamer!

Immer wieder $Df(x^0) verwenden$

Algorithmus:

1. $Df(x^0)\delta^n = -f(x^{(n)})$
2. nach δ^n auflösen
3. $x^{n+1} = x^n + \delta^n$

0.3.2 Gedämpftes Newton-Verfahren

Nach dem n-ten Schritt wenn $Df(x^n)$ schlecht konditioniert ist (nicht oder fast nicht invertierbar), dann $x^n + \delta^n$ verwerfen!!
Funktioniert auch mit vereinfachtes Newton Verfahren.

1 *Probieren:*

$x^n + \dfrac{\delta^n}{2}$

Mit der Bedingung:
$\|f(x^n) + \dfrac{\delta^n}{2})\|_2 < \|f(x^n\|_2$

Weil wir Iteration $\|f(x^n)\|_2$ *gegen 0 erreichen wollen*

Algorithmus:

1. $Df(x^n)\delta^n = -f(x^{(n)})$
2. nach δ^n auflösen
3. Finde minimale aus $k \in \|f(x^n) + \frac{\delta^n}{2})\|_2 < \|f(x^n\|_2$, $k_{max} = 4$
   sofern nichts Anderes als sinnvoll angegeben

```
        while k <= k_max:
                new_residual = np.linalg.norm
                (f_lambda(x_n + (delta.reshape(x0.shape[0], ) /
                (2 ** k))), 2)
#     f (x(n) +     (n) / 2^k)
                if new_residual < last_residual:
                        delta = delta / (2**k)
                        x_next = x_n +
                        delta.reshape(x0.shape[0], )
# x(n+1) = x(n) +     (n) / 2^k
                        k_actual = k
                    break
# Minimales k, f r welches das Residuum besser ist wurde gefunden
-> abbrechen
                else:
                        k=0
        k += 1
```

4. $x^{n+1} = x^n + \frac{\delta^n}{2^k}$